# Grupo 5 - Lenguaje SQL - 2024 TP FINAL

Nombre y apellido	Email		
Ayelén Arias	aaarias@estudiantes.unsam.edu.ar		
Nicole Seinhart	nseinhart@unsam.edu.ar		
Olivia Zantleifer	ozantleifer@estudiantes.unsam.edu.ar		
Maria Belen Quiñones	mquinones@estudiantes.unsam.edu.ar		
Julian Rolando	jdrolando@estudiantes.unsam.edu.ar		
Santiago Mosoni	santimosoni@gmail.com		
Fabiana Fulgenzi	ffulgenzi@iib.unsam.edu.ar		
Agustin Lerer	Lerer918@gmail.com		

# Presentación del motor de base de datos: Empresa/organización que lo provee, libre/pago, etc.

Los motores de bases de datos son fundamentales en el mundo de la tecnología de la información, ya que proporcionan la infraestructura necesaria para almacenar, organizar, recuperar y manipular datos de manera eficiente. Para nuestro trabajo elegimos MySQL que es uno de los motores más utilizados y populares ya que es de descarga gratuita y open source. lo cual hace que pueda encontrarse fácilmente información para su uso.



El motor de trabajo de MySQL consta de varios componentes, incluyendo el servidor MySQL, el motor de almacenamiento, el optimizador de consultas y el planificador de ejecución.

El servidor MySQL actúa como el punto de entrada para las conexiones de clientes y coordina todas las operaciones de base de datos. El optimizador de consultas y el planificador de ejecución trabajan juntos para analizar y ejecutar consultas de la manera más eficiente posible, utilizando índices, estadísticas y otras técnicas de optimización.

Puede ser utilizado para varios sistemas operativos: Linux, Windows, macOS.

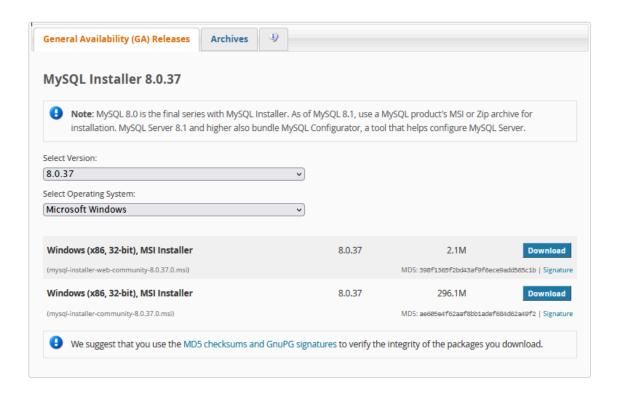
Por su escalabilidad, puede ser utilizado tanto para bases pequeñas como grandes sistemas.

# Cómo conseguirlo, dónde descargarlo.

Al tener una licencia de código abierto puede descargarse la página oficial, donde puede elegirse cual es el sistema operativo y compatibilidad con la máquina del ususario: <a href="https://www.mysql.com/">https://www.mysql.com/</a>

# MySQL Community Downloads

MySQL Installer



#### Instalación & configuración para su uso.

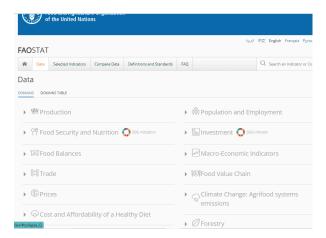
Algunas cuestiones importantes para su instalación es que debe descargarse el paquete completo que incluye MySQL y el MSI Installer.

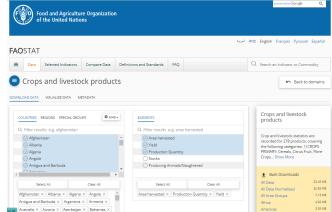
Durante la instalación se pueden editar algunas funciones de arranque, es decir que si queremos que el servidor esté conectado siempre que encendamos la PC o no, por ejemplo.

#### Elección de una Base de datos

Se decidió utilizar datos existentes es un dataset de la FAO.

Se realiza la descarga de los datos de la FAO de producción agrícola ganadera completa ("bulk download" "All data Normalized").





La tabla principal tiene los siguientes datos:

Area Code, Area Code (M49), Area, Item Code, Item Code (CPC), Item, Element Code, Element, Year Code, Year, Unit, Value, Flag

Área: es el país hay datos de todo el mundo

Item: el cultivo o tipo de producción (trigo, maíz, carne de búfalo leche, etc)

**Element:** el tipo de parámetro (rendimiento / Área / producción, etc)

Flag: refiere del tipo de dato (Oficial, estimado, imputed Missing or not applicable, de

organización internacional)

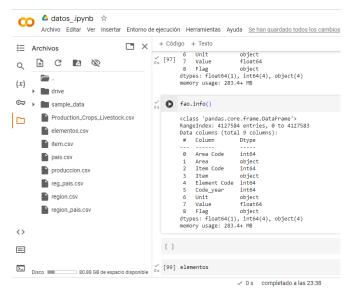
year: datos desde 1961 a 2022

Hay otras tablas accesorias con la codificación de países regiones Items elementos Flag. Como la tabla principal tiene 4.127.584 registros solo pudimos trabajarlos con python a través de google colab ,dado que no se podía abrir con el excel ni importar directamente en sql Workbench en tiempos razonables.

#### Preparación de los datos

En este sentido, se realizó un filtrado de los países de América y del elemento producción quedándonos con 207775 registros, (posteriormente se fueron agregando más datos para la evaluación de rendimiento).

Se borraron algunas columnas para normalizar la base de datos y también se han renombrado columnas para evitar problemas con palabras reservadas como Year, y se reemplazaron los espacios por "\_" y en otros casos simplemente para hacerlos más intuitivos. La tabla de países incluía, las regiones y continentes, por lo que esta tabla se dividió en tres distintas una para cada uno de los "niveles".



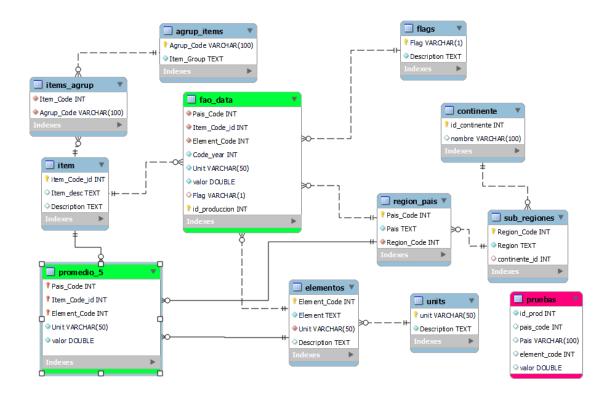
De manera análoga la tabla de ítems también tenía

códigos para la agrupación de las distintas producciones; en este caso solo nos quedamos con las producciones y el primer nivel de agrupación quedando una relación muchos a muchos entre agrup\_items e ítem por lo que se genera la tabla intermedia.

#### Modelo final de la base de datos:

(Archivos 00\_DER\_g5\_fao\_der\_V3.mwb y 01\_SCHEMS\_G5\_fao\_der\_V3.sql)

Se generaron tablas adicionales para el promedio de 5 años y otra de Pruebas para evaluación de rendimiento.



Las tablas armadas con python fueron importadas a mySQL con "data import wizard" y, se generaron las relaciones, se establecieron las PK y FK, y también hubo que ajustar algunos tipos de datos por ejemplo SQL no permite usar como PK un campo tipo "text" cambiándose a varchar()

# **Requerimientos:**

(Archivos 1\_TP\_FINAL\_G5\_Operaciones\_Generales.sql y 2\_TP\_FINAL\_G5\_Queries.sqll)
Operaciones sobre una tabla:

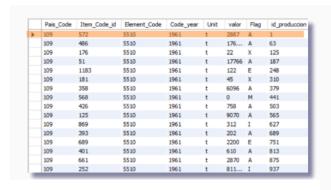
#### Creación

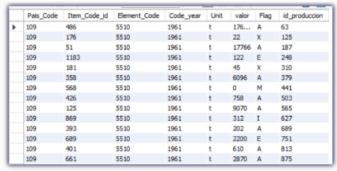
```
CREATE TABLE IF NOT EXISTS `g5_fao_der`.`sub_regiones` (
    `Region_Code` INT NOT NULL,
    `Region` TEXT NOT NULL,
    `continente_id` INT NULL DEFAULT NULL,
    PRIMARY KEY (`Region_Code`),
    CONSTRAINT `fk_continente`
    FOREIGN KEY (`continente_id`)
    REFERENCES `g5_fao_der`.`continente` (`id_continente`))
ENGINE = InnoDB

DEFAULT CHARACTER SET = utf8mb4
COLLATE = utf8mb4_0900_ai_ci;
```

#### Eliminación

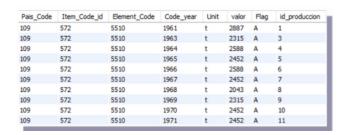
DELETE FROM 'fao\_data' WHERE
Pais\_Code = 109 and item\_Code\_id = 572 and
Element\_Code = 5510 and Code\_Year = 1961;





#### Inserción

INSERT INTO `fao\_data` VALUES (109,572,5510,1962,'t',2315,'A',2);



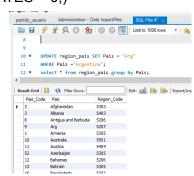
Pais_Code	Item_Code_id	Element_Code	Code_year	Unit	valor	Flag	id_produccion
109	572	5510	1961	t	2887	Α	1
109	572	5510	1962	t	2315	A	2
109	572	5510	1963	t	2315	Α	3
109	572	5510	1964	t	2588	A	4
109	572	5510	1965	t	2452	A	5
109	572	5510	1966	t	2588	A	6
109	572	5510	1967	t	2452	A	7
109	572	5510	1968	t	2043	A	8
109	572	5510	1969	t	2315	Α	9
109	572	5510	1970	t	2452	A	10

#### Actualización

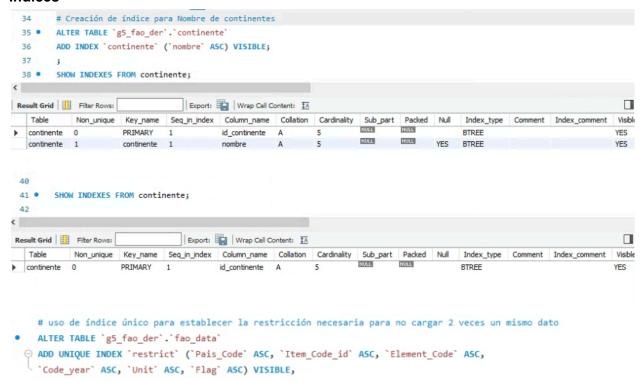
#### cambia Argentina por Arg en el campo País

select \* from region\_pais group by Pais; UPDATE region\_pais SET Pais = "Arg" WHERE Pais ="Argentina"; (requiere SET SQL\_SAFE\_UPDATES = 0;)

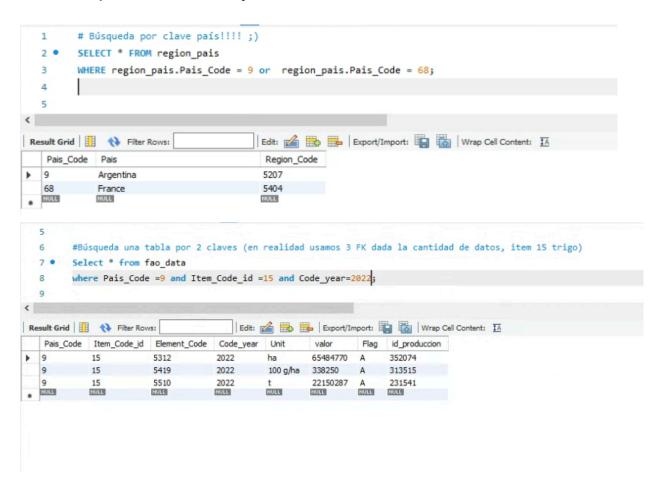




#### Índices



# Búsquedas de una clave y de 2 claves



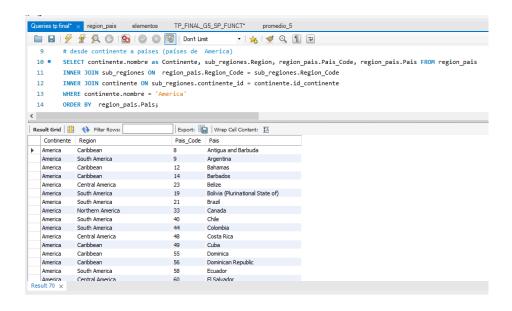
#### Repetir las operaciones para 3 tablas generando una relación con el siguiente aspecto:

Se van a realizar sobre las siguientes tablas:

# continente $\rightarrow$ sub\_regiones $\rightarrow$ region\_pais

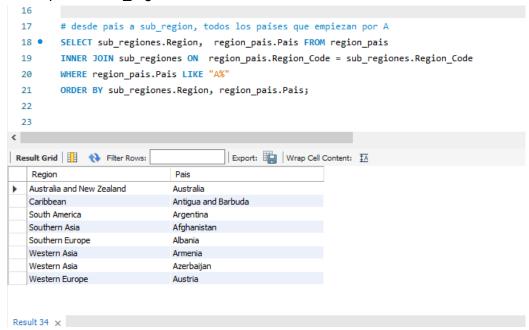
Realizar consultas para la obtención de datos de la siguiente forma:

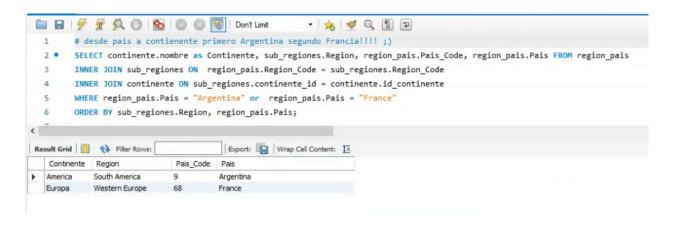
#### A partir de un dato contenido en A conseguir uno de C



#### A partir de un dato contenido en C conseguir uno de B

 $desde\ pa\'{i}s \to sub\_regi\'{o}n$ 

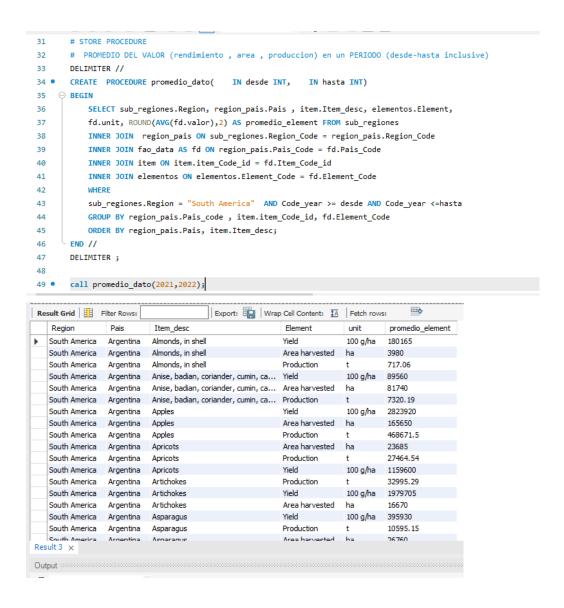




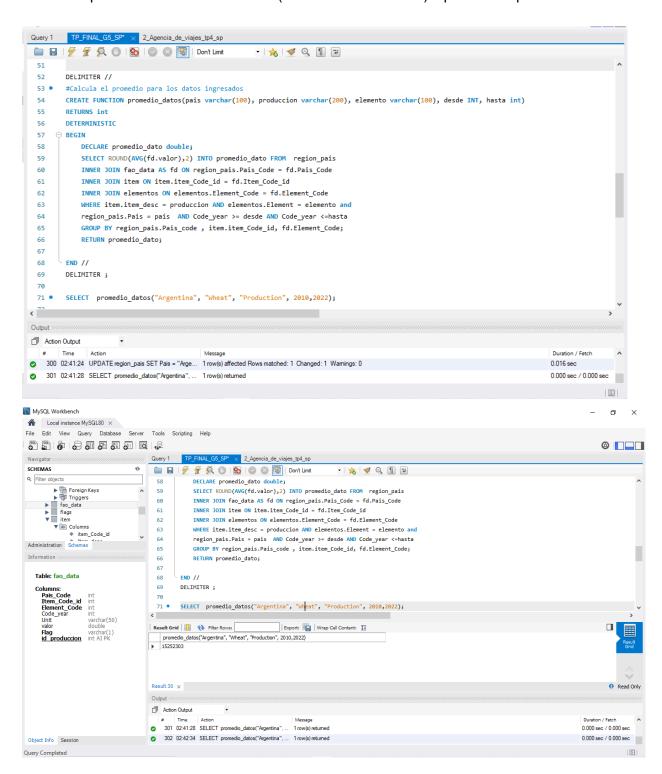
# Realizar Un SP, 1 Function y 1 Trigger y ejemplificar su uso

(Archivo 3\_TP\_FINAL\_G5\_SP\_FUN\_TRIG.sql)

**SP:** calcular promedio de los distintos "elementos" (superficie, rendimiento o producción) para los países se "South América" para el periodo indicado.



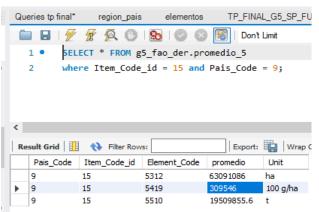
Function: promedio de x últimos años (desde-hasta inclusive) x producto x pais x elemento

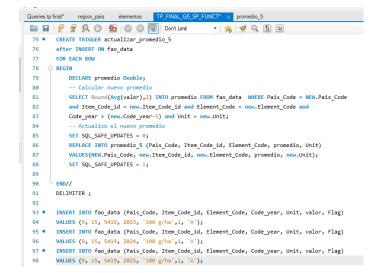


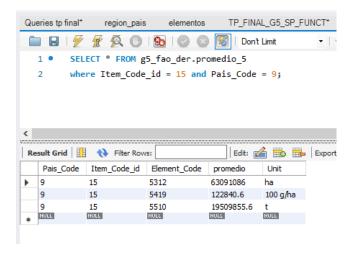
**Trigger:** Informa si se intenta ingresar datos para un país inexistente en la tabla de países (region\_pais)

```
54
        DELIMITER //
55 •
        CREATE TRIGGER pais_inexistente_trigger
56
        BEFORE INSERT ON fao_data
57
        FOR EACH ROW
     ⊖ BEGIN
58
59
            DECLARE pais_existente INT;
60
            DECLARE mensaje VARCHAR(255);
61
             -- Verificar si el nuevo Pais_Code existe en la tabla region_pais
            SELECT COUNT(*) INTO pais_existente FROM region_pais WHERE Pais_Code = NEW.Pais_Code;
62
63
             -- Si el Pais_Code no existe, generar un mensaje de error
64
            IF pais_existente = 0 THEN
65
                 SET mensaje = CONCAT('Pais_code ', NEW.Pais_Code, ' no existente en la tabla region_pais');
66
                 SIGNAL SQLSTATE '45000' SET MESSAGE_TEXT = mensaje;
             END IF:
67
68
        END//
69
        DELIMITER :
70
        INSERT INTO fao_data (Pais_Code, Item_Code_id, Element_Code, Code_year, Unit, valor, Flag)
        VALUES ('569', '572', '6000', '2024', 't', '1000', 'A');
Output :
Action Output
     1 21:28:14 INSERT INTO fao_data (Pais_Code, Item_Code_id, Element_Code, Code_year, Unit, val...
                                                                             Error Code: 1644. Pais_code 569 no existente en la tabla region_pais
                                                                                                                                           0.016 sec
```

**Trigger 2:** Uno de los requerimientos estipulados fue mantener actualizada una tabla de promedio de los últimos 5 años para cada dato/pais/item/elemento







# Análisis de performance:

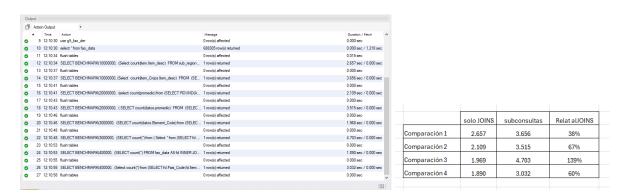
Análisis de performance de consultas consideradas óptimas contra otras consideradas "subóptimas", (con subconsultas ordenamiento y/o agrupamiento por campos no indexados ) Se tomó la precaución de usar "flush tables" previo a cada consulta.

Estas corridas son con 688.305 registros en la tabla principal

#### Archivo 4\_TP\_FINAL\_G5\_benchmark.sql

Se usó la función BENCHMARK de sql que repite la búsqueda determinada cantidad de veces (se ingresa como parámetro el número de repeticiones), esto requiere que el select devuelva un solo dato por lo cual tiene que agregarse una función count(), o alguna otra tipo resumen) a la query que uno quiere testear.

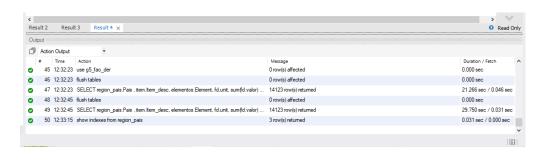
Se hicieron 4 comparaciones de consultas óptimas (solo joins) vs subóptimas (subconsultas con joins o where in)



Las consultas consideradas subóptimas fueron entre un 38% y 140 % más lentas

#### Archivo 5\_ TP\_FINAL\_G5\_Benchmark2

Comparación de uso de campos numéricos vs texto indexados en agrupación y ordenamiento (Esto no se pudo realizar con la función benchmark() por que no permite el ordenamiento ya que al tener que anteponer una función resumen el ordenamiento no tiene sentido)

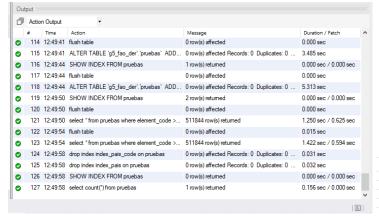


	Numérico	Texto	Relat al nro
	21.266	29.750	40%
_			

Resulta 40 % más lento agrupar y ordenar por texto

#### Archivo 6\_TP\_FINAL\_G5\_ prueba\_benchmark.sql

Para comparar mejor la performance con índices o sin ellos se creó una tabla aparte aislada "pruebas" sin índices, y se corre una consulta ordenada por campo numérico (País Code), otra ordenada por campo texto equivalente (País), se crean los índices y se vuelven a correr.



	Numérico	Texto	Relat al nro
sin índices	1.328	1.438	8%
con índices	1.250	1.422	14%
Relat a sin índices	6%	1%	
creacion indices	3.485	5.313	52%

Se observa que los índices mejoran algo la performance no tanto como se esperaría, pero tal vez la poca dispersión de los datos explicaría esto.

Por otro lado se ve que la indexación de campos tipo varchar() resulta bastante más lenta que la de campo numérico.

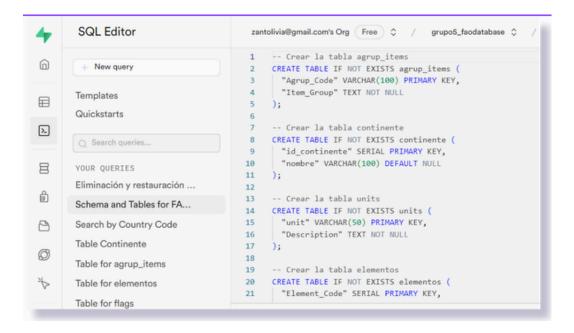
# Migración de la base en la Nube:

Se usó el servicio backend (con PostgreSql), y como interfaz gráfica de usuario (GUI) "TablePlus".





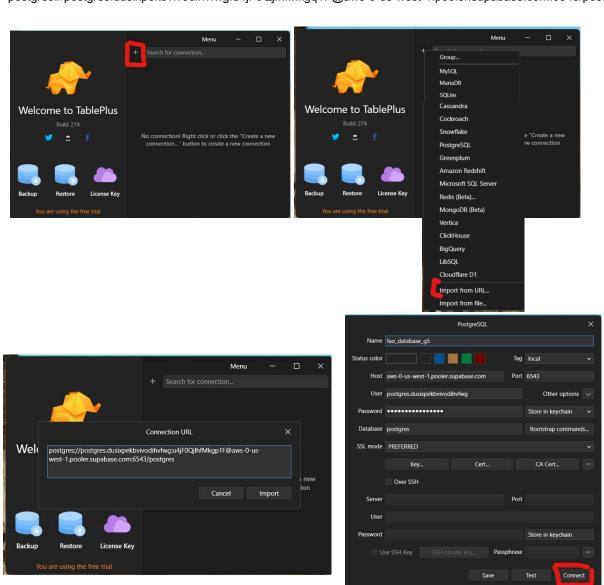


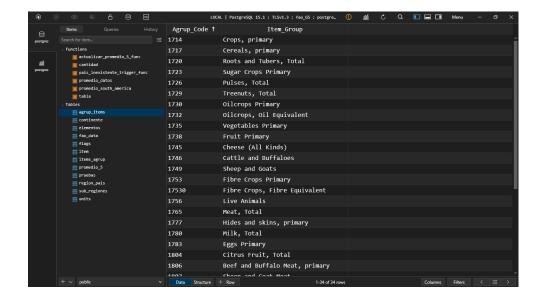


Se repitieron todas las queries y SP/funciones y triggers equivalentes. No se realizó la parte de benchmark dado que no se vio la forma de recuperar el tiempo de las búsquedas.

# Para conectar "Table plus" con "Supabase"

postgres://postgres.dusixpekbvivodihvfwg:u4jF0QjlhfMkgq1F@aws-0-us-west-1.pooler.supabase.com:6543/postgres.dusixpekbvivodihvfwg:u4jF0QjlhfMkgq1F@aws-0-us-west-1.pooler.supabase.com:6543/postgres.dusixpekbvivodihvfwg:u4jF0QjlhfMkgq1F@aws-0-us-west-1.pooler.supabase.com:6543/postgres.dusixpekbvivodihvfwg:u4jF0QjlhfMkgq1F@aws-0-us-west-1.pooler.supabase.com:6543/postgres.dusixpekbvivodihvfwg:u4jF0QjlhfMkgq1F@aws-0-us-west-1.pooler.supabase.com:6543/postgres.dusixpekbvivodihvfwg:u4jF0QjlhfMkgq1F@aws-0-us-west-1.pooler.supabase.com:6543/postgres.dusixpekbvivodihvfwg:u4jF0QjlhfMkgq1F@aws-0-us-west-1.pooler.supabase.com:6543/postgres.dusixpekbvivodihvfwg:u4jF0QjlhfMkgq1F@aws-0-us-west-1.pooler.supabase.com:6543/postgres.dusixpekbvivodihvfwg:u4jF0QjlhfMkgq1F@aws-0-us-west-1.pooler.supabase.dusixpekbvivodihvfwg:u4jF0QjlhfMkgq1F@aws-0-us-west-1.pooler.supabase.dusixpekbvivodihvfwg:u4jF0Qjlhffwgq1F@aws-0-us-west-1.pooler.supabase.dusixpekbvivodihvfwg:u4jF0Qjlhffwgq1F@aws-0-us-west-1.pooler.supabase.dusixpekbvivodihvfwg:u4jF0Qjlhfwgq1F@aws-0-us-west-1.pooler.supabase.dusixpekbvivodihvfwg:u4jF0Qjlhffwgq1F@aws-0-us-west-1.pooler.supabase.dusixpekbvivodihvfwg:u4jF0Qjlhffwgq1F@aws-0-us-west-1.pooler.supabase.dusixpekbvivodihvfwg:u4jF0Qjlhfwgq1F@aws-0-us-west-1.pooler.supabase.dusixpekbvivodihvfwg:u4jF0Qjlhfwgq1F@aws-0-us-west-1.pooler.supabase.dusixpekbvivodihvfwg:u4jF0Qjlhfwgq1F@aws-0-us-west-1.pooler.supabase.dusixpekbvivodihvfwg:u4jF0Qjlhfwgq1F@aws-0-us-west-1.pooler.supabase.dusixpekbvivodihvfwg:u4jF0Qjlhfwgq1F@aws-0-us-west-1.pooler.supabase.dusixpekbvivodihvfwg:u4jF0Qjlhfwgq1F@aws-0-us-west-1.pooler.supabase.dusixpekbvivodihvfwg:u4jF0Qjlhfwgq1F@aws-0-us-west-1.pooler.supabase.dusixpekbvivodihvfwg:u4jF0Qjlhfwgq1F@aws-0-us-west-1.pooler.supabase.dusixpekbvivodihvfwg:u4jF0Qjlhfwgq1F@aws-0-us-west-1.pooler.supabase.dusixpekbvivodihvfwg:u4jF0Qjlhfwgq1F0Qjlhfwgq1F0Qjlhfwgq1F0Qjlhfwgq1F0Qjlhfwgq1F0Qjlhfwgq1F0Qjlhfwgq1F0Qjlhfwgq1F0Qjlhfwgq1F0Qjlhfwgq1F0Qjlhfwgq1F0Qjlhfwgq1F0Qjlhfwgq1F0Qjlhfwgq1F0Qjlhfwgq1F0Qjlhfwgq1F0Qjlhfwgq





Se repitieron todas las queries, SP/funciones y triggers equivalentes. No se realizó la parte de benchmark dado que no se vio la forma de recuperar el tiempo de las búsquedas. (archivo 7\_postgreSQL\_G5.sql)

